# 2026/3/25

# 一、论文想讲的核心故事

## 1. 背景

Agent skill 正在快速涌现，但现有研究主要集中在三类问题：

第一类是 **skill 有没有用**。SkillsBench 给出了目前最系统的答案：它构建了 86 个任务、11 个领域、deterministic verifiers，比较 no-skill、curated skill 和 self-generated skill，发现 curated skills 平均能带来 16.2 个百分点的通过率提升，但效果高度依赖领域，而且 84 个任务中有 16 个是负增益；它还观察到在一些场景里“小模型 + skill”可以接近“大模型无 skill”。

第二类是 **海量 skill 怎么组织和编排**。AgentSkillOS 的核心是 capability tree 检索和 DAG orchestration，目标是在大规模 skill 生态里高效地发现、选择和组合多个 skills，并在 30 个 artifact-rich tasks 上验证树检索和结构化编排的收益。

第三类是 **小模型 / 低资源环境里 skill 有没有价值**。Agent Skill Framework 明确指出，在工业场景里，持续依赖公共 API 往往受预算和数据安全约束，因此需要研究小语言模型能否借助 Agent Skill 受益；它发现 tiny models 的 skill 选择并不稳定，但 12B–30B 一档的中等 SLM 能从 skill 范式中显著受益，某些大一点的 code-specialized 开源模型甚至能接近闭源基线。

## 2. 现有工作的空白

现有工作还没有把下面这个问题正式 benchmark 化：

> **当我们只能用低成本 agent 时，哪些 skills 真正能帮助它逼近高成本 agent？而这种“缩小差距的潜力”，能否在昂贵 full execution 之前用廉价信号预测出来？**

# 二、论文的核心问题定义

我们不再做一个泛泛的“优质 skill 数据集”，也不做一个泛泛的“最强 skill selector”。

这篇论文的核心问题是：

## Can skills close the cost-quality gap for low-cost agents, and can cheap pre-execution signals predict that benefit?

也就是：

1. **skill 能不能帮助低成本 agent 缩小和高成本 agent 之间的性能差距？**
2. **哪些 skill 更擅长补低成本 agent 的短板？**
3. **这种“缩差价值”能不能在 full-run 前由廉价 proxy 信号估计？**
4. **在预算约束下，这样的预估是否真的能帮助做出更好的 skill 选择？**

这样一来，论文的重点不再是“给 skill 打一个分”，而是研究：

## 低成本评估信号与昂贵真实 utility 之间的关系。

# 三、和现有工作的区别

## 与 SkillsBench 的区别

SkillsBench 研究的是 **skill 是否提升 end-to-end performance**；我们的工作研究的是 **skill 是否帮助低成本 agent 逼近高成本 agent，以及这种 gap-closing benefit 能否被廉价信号预测**。前者是 usefulness benchmark，后者是 gap-closing + proxy-evaluation benchmark。

## 与 AgentSkillOS 的区别

AgentSkillOS 研究的是 **如何在大规模 skill 生态中组织、检索、编排多个 skills**；我们不做 skill tree 或 orchestration system，而是把 focus 放在 **pre-execution evaluation**：如何在真正执行前估计 skill 对低成本 agent 的价值。

## 与 Agent Skill Framework 的区别

Agent Skill Framework 已经说明 skill 对中等规模 SLM 有价值，但它不是一个围绕“缩差价值”构造的 benchmark，也没有系统研究哪些廉价信号能预测这种收益。我们的工作相当于把“小模型受益于 skill”从一个现象推进成一个系统的评测问题。

# 四、论文的核心贡献

## Contribution 1

提出第一个围绕 **cost-quality gap closing** 的 agent skill benchmark，形式化“低成本 agent 借助 skill 逼近高成本 agent”的评测问题。这个问题受到 SkillsBench 关于

“小模型 + skill 可接近大模型无 skill”现象的启发，但此前没有被单独 formalize 成 benchmark。

## Contribution 2

构建一个带有结构化 skill 标注、cheap pre-execution signals、以及 sparse downstream full-run labels 的数据集，使研究者可以分析哪些信号能低成本预测 gap-closing benefit。

## Contribution 3

提出一组围绕 **Gap-Closing Gain**、**budgeted gap closing** 和 **cost-adjusted utility** 的评测任务，推动 skill 研究从“有没有用”走向“在预算受限时有没有真正部署价值”。

## Contribution 4

系统分析哪些 tasks、哪些 skills、哪些廉价 proxy 最能帮助低成本 agent 缩小差距，以及 proxy 在哪些条件下会失效。

# 五、整体框架

## Layer 1：Skill Pool

收集 600–1000 个公开 skills，来源可以是公开 registry、GitHub repo、论文附带 skill 包等。这里不追求生态全覆盖，而是追求：

- domain 多样
- function 多样
- 结构质量较好
- 有代表性的风险差异和复杂度差异

这和现有生态分析的发现一致：skill 生态规模大且存在明显冗余，因此 benchmark 需要的是一个结构化、可控而不是无限大的样本池。

## Layer 2：Structured Skill Annotations

给每个 skill 做统一标注，建议包括：

- domain

- function type
- modality
- required tools
- code/template presence
- dependency complexity
- side-effect risk
- canonical use case
- near-miss use case
- 一个额外标签：**likely shortcoming addressed**

  比如是补格式、补流程、补工具使用、补领域 checklist，还是补推理结构

## Layer 3：Task Suite

选 6 个左右的 domain，总计约 40 个任务。优先选择：

- 小模型和大模型之间有明显差距
- skill 有明确介入空间
- 自动评估容易
- 不依赖复杂 GUI 或开放网页长链交互

推荐的域：

- structured extraction / normalization
- retrieval + constrained synthesis
- bounded code repair / code generation
- document transformation / formatting
- data / table manipulation
- bounded tool-use workflow

## Layer 4：Agent Tiers

定义两层主角：

- **Tier H：high-cost frontier agent**
- **Tier L：low-cost agent**

主文里建议只放：

- 1 个高成本参考 agent
- 2 个以上低成本 agent

这样足够讲清故事，又不会把实验变量搞炸。现在 API 官方价格页和模型分层都能清楚看到旗舰档与 mini/nano/flash-lite 档之间的明显差异，因此按相对 tier 定义而不是按绝对美元价格定义，会更稳。

## Layer 5：Signals + Sparse Gold Labels

对每个 task-skill pair 提取三类信号：

### A. Static signals

- 文本长度
- 文件数
- code presence
- tool requirements
- tag overlap
- risk tags
- dependency complexity

### B. Micro-probes

非常便宜的小测试：

- trigger match
- instruction clarity
- output format sanity
- obvious incompatibility
- first-step plausibility

### C. Partial traces

比 probe 贵一点，但远低于 full-run：

- 前 1–2 步规划
- first valid action latency

- first tool call success
- scaffold / intermediate artifact quality

同时只对部分 pair 做 expensive full-run，形成 sparse gold labels。

# 六、核心指标

## 1. Task score

先为每个任务定义一个统一方向的 task score **S**，越大越好。

它可以是：

- pass/fail
- 自动评分
- 归一化后的 task metric

## 2. Gap-Closing Gain（主指标）

对一个低成本 agent 和一个 skill $k$，定义：

- $S_{L,0}$：低成本 agent，无 skill
- $S_{L,k}$：低成本 agent，使用 skill $k$
- $S_{H,0}$：高成本 agent，无 skill

定义：

$$GCG(k) = \frac{S_{L,k} - S_{L,0}}{\max(\epsilon,\ S_{H,0} - S_{L,0})}$$

直观解释：

- $GCG = 0$：skill 没有帮助缩差
- $GCG = 1$：低成本 agent 完全追平高成本无-skill baseline
- $GCG > 1$：超过高成本 baseline
- $GCG < 0$：skill 反而伤害了低成本 agent

这个指标直接把你现在最核心的故事 formalize 了。

## 3. 辅指标

### Absolute Lift

$$\Delta_{abs} = S_{L,k} - S_{L,0}$$

### Cost labels

- extra tokens
- extra latency
- extra tool calls

### Cost-adjusted gap closing

把 gap-closing 和额外成本结合起来看，服务 budget-aware 任务。

# 七、benchmark 任务定义

建议主文至少有三个 benchmark 任务。

## Task 1：Gap-Closing Value Prediction

输入：

- task
- skill
- low-cost agent metadata
- cheap signals

输出：

- 预测该 skill 的 gap-closing gain
- 或多头预测：GCG、Absolute Lift、额外 cost

评价：

- RMSE / MAE
- Pearson / Spearman
- pairwise win accuracy
- calibration

### 这个任务回答的问题

廉价信号能否预测一个 skill 对低成本 agent 的“缩差价值”。

## Task 2：Skill Ranking for Low-Cost Agents

输入：

- 一个 task
- 一个低成本 agent
- 一组 candidate skills

输出：

- 排序列表

评价：

- NDCG@k
- Recall@k
- top-1 / top-3 hit
- pairwise ranking accuracy

### 这个任务回答的问题

如果真实系统要给便宜 agent 选 skill，cheap proxies 能不能支持有效排序。

---

## Task 3：Budget-Constrained Gap Closing

输入：

- 任务
- 低成本 agent
- 候选 skill 集合
- 预算约束

预算可以是：

- max token
- max latency
- no state-changing skills
- low-risk only

输出：

- 选择一个 skill 或 small set

评价：

- constrained GCG
- constrained success
- regret vs oracle
- average cost

### 这个任务回答的问题

在真实部署约束下，cheap pre-execution screening 是否真的有价值。

---

# 八、实验设计

## 1. 数据集规模建议

第一版建议：

- **600–1000 个 skills**
- **约 40 个 tasks**
- **6 个 domains**
- 每个 task 配 **20–50 个 candidate skills**
- 总 skill-task pairs：**3000–5000**
- full-run gold pairs：**1000–2000**

这已经足够做出一篇完整 benchmark paper。

## 2. agent 设置

主文最少需要：

- 1 个 Tier H agent
- 2 个 Tier L agent

每个 task 至少跑：

- Tier L, no skill
- Tier L, with skill

- Tier H, no skill

如果资源允许，附录可以再补：

- Tier H, with best skill
- 一个 ultra-low-cost model

# 3. baseline

## 朴素 baselines

- random
- BM25 / lexical overlap
- embedding similarity
- tag overlap

## 稍强 baselines

- LLM judge
- cross-encoder reranker
- static-signal model
- cheap-signal fusion model

## 上界

- oracle by full evaluation

# 4. 主实验问题

实验一定要围绕下面几件事展开：

## E1.

cheap signals 是否能预测 GCG?

## E2.

哪些 signals 最有用?

- text only
- text + tags

- 
  - micro-probes
- 
  - partial traces

### E3.

哪些 domain 最适合 gap-closing?

- structured extraction 可能容易
- open-ended synthesis 可能难

### E4.

哪些 skill 类型最擅长补低成本 agent 的短板?

- formatting / template skills
- procedural tool-use skills
- checklist-based domain skills

### E5.

在预算约束下，cheap screening 是否真的能节省 expensive evaluation，并维持接近 oracle 的效果?

### E6.

哪些场景下 cheap proxies 明显失效?

这个 failure analysis 一定要有。

---

# 九、图表建议

## 图 1：Problem Overview

一张总览图，展示：

- low-cost agent
- high-cost reference agent
- candidate skills

- cheap signals
- sparse full-run labels
- output: gap-closing prediction / ranking / constrained selection

## 图 2：Dataset Construction Pipeline

raw skill collection → cleaning & dedup → annotation → candidate set construction → cheap probes → sparse full-run → benchmark tasks

## 图 3：Cost–Quality Frontier

横轴：成本

纵轴：质量 / 任务得分

画出：

- low-cost, no skill
- low-cost + random skill
- low-cost + proxy-selected skill
- low-cost + oracle-selected skill
- high-cost, no skill

这张图会非常强，因为它直观展示“低成本 agent 是否在逼近高成本基线”。

## 图 4：Gap-Closing Distribution by Domain

看不同 domain 上 GCG 的分布，展示哪些任务最适合 skill 缩差，哪些任务最难。

## 图 5：Signal Ablation

比较：

- text only
- · tags
- · micro-probes
- · partial traces

展示不同信号组合对 GCG prediction / ranking 的提升。

## 图 6：Failure Cases

展示 cheap proxy 选错 skill 的案例：

- 为什么看起来像是对的
- 为什么 full-run 之后失败
- 是因为工具不兼容、格式误导，还是 shortcoming mismatch

---

# 十、正文表格建议

## 表 1：与现有工作的对比

列：

- evaluates usefulness
- studies large-scale organization
- targets small/cheap agents
- studies pre-execution proxies
- studies gap-closing
- includes budget constraints
- includes safety/risk as a dimension

## 表 2：数据集统计

- #skills
- #tasks
- #domains
- avg skill length
- #candidate skills per task
- #gold full-run pairs
- risk distribution
- function distribution

## 表 3：Gap-Closing Prediction 结果

- RMSE
- Spearman
- pairwise accuracy
- calibration

## 表 4：Ranking 结果

- NDCG@5
- Recall@5
- MRR
- top-1 hit

## 表 5：Budgeted Gap Closing 结果

- constrained GCG
- constrained success
- average cost
- regret vs oracle

## 表 6：Signal Ablation

- text
- text+tags
- +static
- +probes
- +partial traces

---

# 十一、论文的核心 insight 应该是什么

你们最终不能只交一个 leaderboard，而是要交出几条明确 insight。

## 可能的核心 insight

第一，**skill 对低成本 agent 的帮助是高度异质的**；不是所有 skill 都能缩差，也不是所有 tasks 都适合用 skill 去补。SkillsBench 已经提示了这种领域异质性，但你们会把它具体化到 low-cost vs high-cost gap 上。

第二，**某些廉价信号足以预测结构化任务中的 gap-closing potential，但对开放性更强的任务明显失效**。这就是 benchmark 的科学价值所在。

第三，**补小模型短板的好 skill 不一定是“全局最强 skill”**。有些 skill 对强模型提升不大，但对弱模型特别有效；这正是你们 benchmark 的独特发现空间。

第四，**budget-aware skill selection 是必要的**。因为低成本 agent 本身的价值就来自预算优势，如果为了 gain 一点提升却把额外 token 和 latency 全部吃掉，那 deployment 价值会大打折扣。

---

# 十二、审稿人可能会问什么，你们需要怎么回应

## Q1：为什么不是直接 full-run 所有 skill?

因为论文的研究对象就是：在生态规模增大时，full-run 全量评测代价太高，是否存在可靠的 cheap surrogate。NeurIPS 2026 E&D track 也明确鼓励 evaluation 本身的科学研究。

## Q2：这是不是只是一个 reranking benchmark?

不是。ranking 只是任务形式之一；论文核心是分析廉价 pre-execution signals 与真实 downstream gap-closing utility 的关系。

## Q3：为什么 gap-closing 比绝对分数更重要?

因为你们聚焦的是现实里最重要的目标：**低成本 agent 能不能少花钱、尽量不掉效果**。这比抽象的 absolute skill score 更贴近 deployment。

## Q4：为什么这个问题现在值得研究?

因为现有研究已经分别指出：

- curated skills 确实有用，但高度异质。
- 大规模 skill 生态的组织与选择已经成为问题。
- 小模型 / 预算受限 agent 确实会受益于 skill，但机制和边界还不清楚。

你们做的正是把这三件事交叉起来。

---

# 十三、当前版本的一句话总结

## 最推荐的一句话 pitch

**我们提出一个新的 agent skill benchmark，用来评估哪些 skill 能在预算受限场景下帮助低成本 agent 逼近高成本 agent，并研究哪些廉价的 pre-execution signals 能预测这种 gap-closing benefit，而无需对所有技能做昂贵的 full execution。**

---

**项目当前版本摘要：**

我们计划做一个 NeurIPS 2026 E&D track 风格的 benchmark / dataset 工作，核心问题不是“skill 有没有用”，也不是“怎么组织海量 skills”，而是：在预算受限场景下，skill 是否能帮助低成本 agent 逼近高成本 agent，以及这种 gap-closing benefit 能否被廉价的 pre-execution signals 预测。

我们会收集 600–1000 个 skills，做统一标注；设计约 40 个结构化、可自动评估的任务，覆盖 6 个 domain；定义 low-cost tier 和 high-cost tier agents；对 task-skill pairs 提取 static signals、micro-probes 和 partial traces，并对部分 pairs 做 sparse full-run，形成 gold labels。

benchmark 包含三个主任务：

1）Gap-Closing Value Prediction；

2）Skill Ranking for Low-Cost Agents；

3）Budget-Constrained Gap Closing。

主指标是 Gap-Closing Gain（GCG），衡量一个 skill 是否帮助低成本 agent 缩小与高成本 agent 的差距。

论文重点不是做最强 selector，而是研究 cheap proxies 与真实 downstream utility 的关系，以及它们在什么任务、什么 skill 类型、什么预算约束下有效或失效。